

Trimestre 21-I

Minería de datos Práctica 2 "Más sobre regresiones"

La práctica se deberá realizar en equipos de 2 personas.

Dataset

1. Dataset para regresión polinomial: polynomial.txt. Tiene un atributo (age) y una variable de salida (length).

Uso de EMO Project

- 1. Como requerimientos previos se necesita una computadora con sistema operativo tipo UNIX (Linux, MacOSX) y tener instalado lo siguiente:
 - a. gcc 4.1.2
 - b. MPI 3.0, MPICH 2.2 (optional)
 - c. GNU Make 3.81
- 2. Descomprimir el archivo EMO_Project1.36.zip.
- 3. Ingresar en el directorio EMO_Project1.36/ utilizando una consola.
- 4. Escribir el comando make clean.
- 5. Una vez que haya terminado el comando anterior, ejecutar el comando make.
- 6. Una vez compilada la aplicación entrar en el directorio EMO_Project1.36/demo/.
- 7. Para ejecutar un algoritmo evolutivo multi-objetivo, hacerlo como sigue: ./emo_moea MOEAD input/Param_03D.cfg DTLZ1 5
- 8. Una vez terminada la ejecución, en el directorio

 EMO_Project1.36/demo/output/ se encontrarán los archivos de salida.

 De estos archivos de salida, todos aquellos con extensión .pos corresponderán con los atributos mientras que los archivos con extensión .pof serán las variables de salidad.
- 9. Para construir un dataset a partir de los archivos de salida, juntaremos en un solo archivo todos los archivos . pos. Asegúrate de quitar de cada archivo la cabecera que lleva puesta (se encuentra en la primera línea de cada archivo y tiene una apariencia: # N M). Al juntar todos los archivos . pos tendremos el dataset completo de atributos. Ahora hay que unir todos los archivos . pof en un único archivo como se hizo anteriormente. Este archivo único contendrá todas las etiquetas de las instancias que se encuentran en el archivo . pos unificado.

Procedimiento para regresión lineal multi-salida

- 1. En EMO_Project ejecutar la siguiente línea: ./emo_moea MOEAD input/Param_03D.cfg DTLZ1 100. Esto generará 7 atributos y 3 variables de salida.
- 2. Generar el dataset como se indica en la sección anterior.
- 3. Generar el training set y test set de forma aleatoria con una proporción 80%-20%, respectivamente.
- 4. Investigar el uso de la regresión lineal multi-salida en Scikit-Learn. En la presentación de la clase pasada (12/04/21) se dio un fragmento de código que será el punto de partida.
- 5. Entrenar el modelo.
- 6. Evaluar el modelo empleando una validación simple.
- 7. Calcular la precisión del modelo y reportarla.
- 8. En una gráfica en \mathbb{R}^3 , presentar las variables de salida del test set y los valores predecidos por el modelo (usar color rojo para las variables de salida del test set y color azul para los valores predecidos). En caso de que no se aprecien correctamente las diferencias entre los puntos, presentar las proyecciones sobre los planos x-y y y-x, tomando en cuenta que el espacio \mathbb{R}^3 está dado por los ejes x,y,z.

Procedimiento para regresión polinomial

- 1. Emplear el dataset polynomial.txt.
- 2. Para este dataset se ocupara el método de evaluación por Bootstrapping.
- 3. Investigar el uso de la regresión polinomial en Scikit-Learn. En la presentación de la clase pasada (12/04/21) se dio un fragmento de código que será el punto de partida.
- 4. Entrenar el modelo.
- 5. Evaluar el modelo empleando una validación simple.
- 6. Calcular la precisión del modelo y reportarla.
- 7. Gráficar el dataset completo y utilizar el modelo para predecir los valores en todos los puntos discretos que toma el atributo age. De esta manera, se podrá comparar el dataset contra la gráfica que predice el modelo de regresión polinomial. Usar color rojo para el dataset y color azul para los valores predecidos.

Reporte de la práctica

Emplear el formato de práctica dado por el profesor y seguir las instrucciones mostradas. El archivo que se subirá a *Google Classroom* deberá estar estrictamente en formato PDF y deberá ser nombrado como report.pdf.

Usar el lenguaje Python para desarrollar la práctica. Únicamente será aceptado este lenguaje para la generación de los programas. Además, es forzoso el uso de Scikit-learn. Entregar el programa con extensión .py debidamente comentado. Entregar un

archivo README.txt donde se exponga cómo ejecutar el programa (indicar los parámetros en caso de necesitarlos) y un ejemplo para cómo ejecutar el programa y producir así los resultados reportados.

Entrega global

Tanto el reporte y el programa deberán ser empaquetados en un archivo .ZIP y nombrarlo: practice2.zip. Cualquier falta a las instrucciones pedidas implicará la anulación de la práctica para todos los integrantes del equipo.